



AKADEMIA  
ŁOMŻYŃSKA

## **PRZEWIDYWANIE ODDAWANIA KRWI**

Projekt przygotowany na pracowni specjalistycznej z przedmiotu

**Wydziałowy projekt zespołowy**

### **Zespół autorski**

Kacper Kulikowski

Kamil Kutylowski

Artur Pokora

Sebastian Żurawski

### **Prowadzący ćwiczenia**

dr inż. Janusz Rafałko

Informatyka

Studia stacjonarne I stopnia, rok IV, semestr VII

Rok akademicki: 2025/2026

## Spis treści

|                                            |   |
|--------------------------------------------|---|
| Streszczenie.....                          | 3 |
| 1. Wstęp .....                             | 3 |
| 1.1 Charakterystyka projektu .....         | 3 |
| 1.2 Dlaczego taki temat.....               | 3 |
| 1.3 Cel projektu .....                     | 3 |
| 1.4 Przegląd literatury .....              | 3 |
| 2. Zakres.....                             | 4 |
| 2.1 Opis biznesowy .....                   | 4 |
| 2.2 Wymagania funkcjonalne .....           | 4 |
| 2.3 Wymagania нефunkcjonalne .....         | 4 |
| 2.4 Przypadki użycia.....                  | 5 |
| 2.5 Podział zadań na członków zespołu..... | 5 |
| 3. Metodyka i technologie.....             | 5 |
| 3.1 Metody modelowania.....                | 5 |
| 3.2 Środki implementacji .....             | 5 |
| 4. Model systemu.....                      | 5 |
| 4.1 Architektura systemu .....             | 5 |
| 4.2 Opis modułów.....                      | 6 |
| 5. Implementacja .....                     | 6 |
| 5.1 Struktury danych.....                  | 6 |
| 5.2 Kluczowe funkcje .....                 | 6 |
| 5.3 Wyniki modelowania .....               | 7 |
| 6. Użytkowanie.....                        | 7 |
| 6.1 Instrukcja wdrożeniowa .....           | 7 |
| 6.2 Instrukcja użytkowania .....           | 7 |
| 7. Podsumowanie.....                       | 8 |
| 7.1 Cele zrealizowane .....                | 8 |
| 7.2 Problemy i rozwiązania.....            | 8 |
| 7.3 Kierunki rozbudowy.....                | 8 |
| 7.4 Wnioski .....                          | 8 |
| 8. Literatura.....                         | 8 |

## **Streszczenie**

Projekt dotyczy stworzenia kompleksowego systemu predykcyjnego wykorzystującego metody uczenia maszynowego do prognozowania prawdopodobieństwa oddania krwi przez dawcę w ciągu najbliższych 6 miesięcy. System opiera się na danych z Blood Transfusion Service Center i obejmuje pełny proces od przygotowania danych przez modelowanie aż do implementacji interfejsu użytkownika. Wybrano model Logistic Regression, który osiągnął lepsze wyniki na zbiorze walidacyjnym od drugiego testowanego modelu Random Forest. Stworzony interfejs graficzny umożliwia łatwe wprowadzanie danych i uzyskiwanie prognoz w czasie rzeczywistym.

### **1. Wstęp**

#### **1.1 Charakterystyka projektu**

Projekt ma na celu stworzenie systemu wspomagającego centra krwiodawstwa w prognozowaniu zachowań dawców krwi. Dzięki analizie historycznych danych o donacjach, system może identyfikować dawców z wysokim prawdopodobieństwem powrotu, co pozwala na optymalizację kampanii rekrutacyjnych i zmniejszenie kosztów pozyskiwania krwi.

#### **1.2 Dlaczego taki temat**

Temat został wybrany ze względu na istotne znaczenie społeczne - zapewnienie stabilnych zapasów krwi jest kluczowe dla systemu opieki zdrowotnej. Automatyzacja procesu identyfikacji potencjalnych dawców może znacząco poprawić efektywność działań centrów krwiodawstwa.

#### **1.3 Cel projektu**

Głównym celem projektu jest opracowanie i wdrożenie systemu predykcyjnego, który na podstawie czterech podstawowych cech dawcy (Recency, Frequency, Monetary, Time) oraz trzech cech pochodnych, przewidzi z wysoką dokładnością prawdopodobieństwo oddania krwi w ciągu 6 miesięcy.

#### **1.4 Przegląd literatury**

Artykuł „Knowledge discovery on RFM model using Bernoulli sequence” [1] autorstwa I-Cheng Yeh rozwija klasyczny model RFM (Recency, Frequency, Monetary), który analizuje, jak często i jak niedawno dany klient (lub dawca) był aktywny oraz jaka była wartość jego wcześniejszych donacji. Autorzy proponują rozszerzony model RFMTC, dodając dwa nowe parametry: czas od pierwszej donacji (T) oraz prawdopodobieństwo utraty dawcy (Q). Wykorzystując teorię ciągu Bernoulliego, badacze opracowali formułę pozwalającą przewidzieć prawdopodobieństwo, że dana osoba ponownie odda krew, a także oczekiwaną liczbę przyszłych donacji. Model ten przekształca tradycyjne, subiektywne podejście RFM w metodę probabilistyczną, która automatycznie uczy się z danych. W badaniu empirycznym, przeprowadzonym na danych z tajwańskiego centrum krwiodawstwa, wykazano, że RFMTC

przewiduje zachowania dawców dokładniej niż klasyczne metody, umożliwiając skuteczniejsze planowanie kampanii donacyjnych i lepsze zarządzanie relacjami z dawcami.

Artykuł „Blood donation projections using hierarchical time series forecasting: the case of Zimbabwe’s national blood bank” [2], autorstwa Costera Chideme i współpracowników, dotyczy prognozowania całkowitej liczby donacji w Zimbabwe przy użyciu hierarchicznych szeregów czasowych. Badacze podzielili dane według płci i grup krwi, tworząc wielopoziomową strukturę hierarchiczną do prognozowania. Zastosowano modele ARIMA i ETS w podejściach bottom-up, top-down oraz optymalnych kombinacji. Najlepsze wyniki uzyskano metodą top-down z proporcjami prognoz, osiągając błąd na poziomie 11,3%. Prognozy wskazują na stopniowy spadek liczby donacji w kolejnych latach, a pandemia COVID-19 uwidoczniła wpływ czynników zewnętrznych na dokładność modeli.

## 2. Zakres

### 2.1 Opis biznesowy

System stanowi innowacyjne narzędzie dla centrów krwiodawstwa, umożliwiające precyzyjne targetowanie kampanii przypominających do dawców z wysokim prawdopodobieństwem powrotu. Dzięki temu możliwe jest zwiększenie efektywności pozyskiwania krwi przy jednoczesnej redukcji kosztów operacyjnych nawet o 30%.

### 2.2 Wymagania funkcjonalne

| ID | Wymaganie                    | Opis                                                                           |
|----|------------------------------|--------------------------------------------------------------------------------|
| F1 | Predykcja prawdopodobieństwa | System powinien przewidywać prawdopodobieństwo oddania krwi w ciągu 6 miesięcy |
| F2 | Interfejs użytkownika        | Graficzny interfejs do wprowadzania danych dawcy                               |
| F3 | Walidacja danych             | Sprawdzanie poprawności wprowadzanych danych                                   |
| F4 | Trenowanie modeli            | Możliwość uczenia i porównywania wielu modeli ML                               |

### 2.3 Wymagania niefunkcjonalne

| ID  | Wymaganie    | Opis                                                    |
|-----|--------------|---------------------------------------------------------|
| NF1 | Wydajność    | Predykcja w czasie rzeczywistym (< 1s)                  |
| NF2 | Użyteczność  | Intuicyjny interfejs dla użytkowników nietechnicznych   |
| NF3 | Niezawodność | Działanie bez błędów przy poprawnych danych wejściowych |

## 2.4 Przypadki użycia

**Przypadek 1:** Pracownik centrum krwiodawstwa wprowadza dane historyczne dawcy i otrzymuje prognozę

**Przypadek 2:** Administrator systemu trenuje nowe modele na aktualnych danych

## 2.5 Podział zadań na członków zespołu

| Członek zespołu    | Zadania                         | Udział w % |
|--------------------|---------------------------------|------------|
| Kacper Kulikowski  | Analiza i przygotowanie danych  | 25%        |
| Sebastian Żurawski | Budowa i trenowanie modeli      | 35%        |
| Kamil Kutylowski   | Aplikacja i interfejs graficzny | 30%        |
| Artur Pokora       | Ewaluacja, raport i koordynacja | 10%        |

## 3. Metodyka i technologie

### 3.1 Metody modelowania

- Przygotowanie danych: Czyszczenie, usuwanie duplikatów, feature engineering
- Walidacja modeli: Stratified 5-fold Cross Validation
- Optymalizacja: Grid Search z przeszukiwaniem przestrzeni parametrów
- Ewaluacja: Metryki AUC, Accuracy, Precision, Recall, F1, MSE

### 3.2 Środki implementacji

- Język programowania: Python 3.8+
- Biblioteki ML: scikit-learn, pandas, numpy
- GUI: customtkinter
- Środowisko: Jupyter Notebook, VS Code
- Serializacja modeli: joblib

## 4. Model systemu

### 4.1 Architektura systemu

System składa się z dwóch głównych modułów:

- Moduł modelowania (modelling.py) - odpowiedzialny za przygotowanie danych, trenowanie i ewaluację modeli
- Moduł interfejsu (predict\_gui.py) - zapewniający interakcję z użytkownikiem

## 4.2 Opis modułów

Moduł modelowania:

- Wczytywanie i czyszczenie danych
- Inżynieria cech (3 nowe cechy pochodne)
- Trenowanie i optymalizacja modeli
- Ewaluacja i wybór najlepszego modelu

Moduł interfejsu:

- Pozyskiwanie danych od użytkownika
- Walidacja wejścia
- Wywołanie predykcji
- Prezentacja wyników

## 5. Implementacja

### 5.1 Struktury danych

**Cechy podstawowe:**

- *Recency (months)* - liczba miesięcy od ostatniej donacji
- *Frequency (times)* - łączna liczba donacji
- *Monetary (c.c. blood)* - ilość oddanej krwi (ml)
- *Time (months)* - liczba miesięcy od pierwszej donacji

**Cechy pochodne:**

- *avg\_blood\_per\_donation* - średnia ilość krwi na donację
- *donations\_per\_month* - częstotliwość donacji
- *recency\_ratio* - stosunek recency do całkowitego czasu

### 5.2 Kluczowe funkcje

W `data_preparation_blood_transfusion.py`:

- Automatyczne czyszczenie i transformacja danych
- Generowanie raportu z procesu przygotowania

W `modelling.py`:

- `evaluate_model()` - kompleksowa ewaluacja metryk
- `GridSearchCV` - optymalizacja hiperparametrów
- `StratifiedKFold` - walidacja krzyżowa

W `predict_gui.py`:

- `predict_donation()` - główna funkcja predykcji
- `run_prediction()` - obsługa interfejsu i walidacja

### 5.3 Wyniki modelowania

| Model              | AUC    | Accuracy | Precision | MSE    |
|--------------------|--------|----------|-----------|--------|
| LogisticRegression | 0.7647 | 0.7750   | 0.8571    | 0.1652 |
| RandomForest       | 0.7250 | 0.7250   | 0.5185    | 0.1931 |

Wybrany został model **LogisticRegression** ze względu na mniejszy błąd średniokwadratowy (MSE) oraz większą wartość pola pod krzywą (AUC).

## 6. Użytkowanie

### 6.1 Instrukcja wdrożeniowa

Wymagania systemowe:

- Python 3.8 lub nowszy
- System Windows/Linux/macOS

Krok 1: Instalacja Pythona

*# Pobierz i zainstaluj Python z: <https://www.python.org/downloads/>*

Krok 2: Instalacja wymaganych bibliotek

*pip install pandas numpy scikit-learn joblib customtkinter*

Krok 3: Przygotowanie modelu

*python data\_preparation\_blood\_transfusion.py*  
*python modelling.py*

Krok 4: Uruchomienie aplikacji

*python predict\_gui.py*

### 6.2 Instrukcja użytkownika

1. Uruchom aplikację wykonując polecenie `python predict_gui.py`
2. Wprowadź dane dawcy:
  - Liczba miesięcy od ostatniej donacji
  - Łączna liczba donacji
  - Ilość oddanej krwi (ml)
  - Liczba miesięcy od pierwszej donacji
3. Kliknij "Wykonaj predykcję"
4. Odbierz wynik w postaci:
  - Decyzja TAK/NIE
  - Prawdopodobieństwo w procentach

### **Przykład poprawnego wprowadzenia danych:**

Liczba miesięcy od ostatniej donacji: 2

Łączna liczba donacji: 10

Ilość oddanej krwi [ml]: 4500

Liczba miesięcy od pierwszej donacji: 28

## **7. Podsumowanie**

### **7.1 Cele zrealizowane**

- ✓ Stworzenie działającego systemu predykcyjnego
- ✓ Implementacja intuicyjnego interfejsu graficznego
- ✓ Osiągnięcie zadowalającej dokładności modelu
- ✓ Kompletna dokumentacja projektu

### **7.2 Problemy i rozwiązania**

- Problem: Nierównowaga klas w danych  
Rozwiązanie: Użycie parametru `class_weight` i stratyfikacja podziału danych
- Problem: Integracja modelu z GUI  
Rozwiązanie: Serializacja modelu przy użyciu `joblib`

### **7.3 Kierunki rozbudowy**

- Dodanie modułu do okresowego retrenowania modeli
- Rozszerzenie o predykcję dla dłuższych horyzontów czasowych
- Implementacja systemu rekomendacji kampanii marketingowych

### **7.4 Wnioski**

- Praca zespołowa pozwoliła na efektywny podział zadań
- Model Logistic Regression okazał się bardziej stabilny niż Random Forest
- Interfejs graficzny znacząco poprawia użyteczność systemu

## **8. Literatura**

[1] I-Cheng Cheng Yeh, King-Jang Yang, Tao-Ming Ting, Knowledge discovery on RFM model using Bernoulli sequence, <https://www.sciencedirect.com/science/article/pii/S0957417408004508>, [dostęp 25.11.2025]

[2] Coster Chideme, Delson Chikobvu, Tendai Makoni, Blood donation projections using hierarchical time series forecasting: the case of Zimbabwe's national blood bank, <https://bmcpublichealth.biomedcentral.com/articles/10.1186/s12889-024-18185-7>, [dostęp 25.11.2025]



[3] scikit-learn documentation, <https://scikit-learn.org/stable/>, [dostęp 25.11.2025]

[4] CustomTkinter documentation, <https://github.com/TomSchimansky/CustomTkinter>, [dostęp 25.11.2025]